Empório da Música - agente de atendimento

Luccas Bassani | Desafio técnico de AI Engineer - Artefact | 03/11/2026

Repositório do projeto

Protótipo em Python para responder dúvidas sobre instrumentos, preços, disponibilidade, pedidos e políticas da loja. Priorizei uma aplicação local simples de executar, com consultas verificáveis aos dados fornecidos e exemplos reais de atendimento.

Escopo e persona

A Lia atende em português, com tom acolhedor, objetivo e consultivo. Deve aproveitar o contexto, fazer uma pergunta necessária por vez e redirecionar assuntos fora da loja. Em devoluções e garantias, orienta a análise pela equipe sem aprovar solicitações.

Defini a referência de interface, a persona e o escopo. A tela permite configurar o agente, conversar, conferir consultas e exportar conversas e configurações. A implementação é independente da referência utilizada e concentra a aplicação em Python.

Arquitetura e decisões técnicas



- **Python e Streamlit:** interface e agente na mesma linguagem, com pouca configuração para demonstrar o atendimento.
- **Function calling e funções Python:** o modelo escolhe entre cinco ferramentas; o código valida argumentos, consulta CSVs e calcula preços com `Decimal`. O volume fornecido permite consultas diretas, sem banco de dados adicional.
- **RAG lexical com BM25:** o manual é pequeno. A busca local recupera até quatro trechos, preservando seção e página, sem exigir um serviço de embeddings.
- **Gemini Flash-Lite na demonstração:** suporte a ferramentas e capacidade gratuita observada nos testes. Groq é alternativa configurável; Ollama é opção local implementada, ainda sem validação com modelo instalado.

O agente usa `httpx`, sem framework de agentes, para manter explícito o ciclo de chamada, execução e retorno das ferramentas. O prompt separa regras de consulta, limites e fontes das preferências de estilo. O contexto mantém os dois turnos anteriores completos.

Instalação e execução

Requer Python 3.12 ou superior. Ambiente conferido: Windows com Python 3.14.4. No PowerShell, dentro da pasta do repositório:

```
python -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements.lock.txt
Copy-Item .env.example .env
```

Copie o exemplo apenas na primeira configuração. No `.env`, selecione Gemini e preencha sua chave, criada no Google AI Studio:

```
LLM_PROVIDER=gemini
GEMINI_API_KEY=sua_chave
GEMINI_MODEL=gemini-3.5-flash-lite
```

```
.\.venv\Scripts\python.exe -m streamlit run app.py
```

Abra http://127.0.0.1:8501. A Lia já vem configurada. Para testar pedidos, selecione **Cliente #2** e consulte o **pedido 8**; o **Cliente #6** tem o **pedido 9**, sem rastreamento. O expansor de cada resposta mostra consultas e fontes. A captura da interface apresenta o fluxo.

Trocar cliente, aplicar configuração ou iniciar nova conversa limpa o histórico atual. Os botões de download salvam a conversa em Markdown/TXT e a configuração em JSON. Chaves ficam no `.env`, fora do Git e das exportações; reinicie o servidor após alterá-las. Variáveis já definidas no processo têm prioridade sobre o arquivo.

Outros provedores

Para Groq, use `LLM_PROVIDER=groq`, `GROQ_API_KEY` e `GROQ_MODEL=qwen/qwen3.8-27b`. Para Ollama, instale o servidor, execute `ollama pull qwen3:8b` e use `LLM_PROVIDER=ollama`, `OLLAMA_MODEL=qwen3:8b` e `OLLAMA_BASE_URL=http://127.0.0.1:11434`.

A seleção é explícita, sem troca automática de provedor. APIs externas dependem das cotas da conta. No nível gratuito do Gemini, confira as condições de uso dos dados; esta demonstração utiliza dados fictícios e omite contatos pessoais nas consultas ao modelo.

Testes e terminal

```
.\.venv\Scripts\python.exe -m unittest discover -s tests -v
.\.venv\Scripts\python.exe -m emporio --help
```

Os testes locais não precisam de chave ou rede. O terminal também oferece catálogo, busca de políticas e chat. `--check` e `--test-tools` fazem chamadas reais de diagnóstico ao provedor selecionado.

Regras de dados e validação

Disponibilidade exige status ativo e estoque positivo. Uma promoção cadastrada como ativa prevalece sobre o desconto PIX, sem acumulação. Totais históricos dos pedidos são preservados. Divergências cadastrais e lacunas do manual ficam em notas separadas, sem alterar as fontes originais.

A aplicação fixa o cliente fora dos argumentos do modelo e restringe os pedidos a essa seleção. Pedido ausente e pedido de outro cliente recebem a mesma orientação. As ferramentas de pedidos retornam somente os campos operacionais necessários, sem nomes ou contatos de clientes.

61 testes automatizados passaram, cobrindo preços, acesso a pedidos, recuperação, contratos dos provedores e interface. As respostas de API são simuladas nesses testes. Uma avaliação com API real cobriu **32 cenários: 12 aprovados, 15 com ressalvas e cinco falhas**. Após correções, os cinco casos tiveram o objetivo principal atendido nos retestes, com ressalvas em dois deles. Uma regressão de frete no texto de pedido também foi corrigida e repetida.

Não houve nova rodada integral após a última correção. O relatório de avaliação distingue as revisões. Há cinco exemplos reais, também apresentados na seção de exemplos de atendimento e revisão.

Limitações e próximos passos

- A recuperação lexical pode perder reformulações; citações válidas não comprovam toda afirmação. Tom, triagem e condições de preço ainda variam na geração.
- O cliente é selecionado para demonstração, sem autenticação real. CSVs são uma fotografia; o agente não executa compras, devoluções ou consultas ao vivo à transportadora.
- O histórico fica na sessão, com dois turnos anteriores no contexto. Ollama ainda precisa de teste com modelo local; APIs externas dependem de disponibilidade e cota.

Com mais tempo, priorizaria guardrails, triagem estruturada e memória de atendimentos anteriores. Para bases maiores, avaliaria busca híbrida no RAG e consultas a banco de dados ou APIs. Fine-tuning seria um experimento posterior para tom e comportamento, com conversas revisadas e avaliação independente. As propostas estão detalhadas na seção Melhorias com mais tempo.

Uso de IA e condução do trabalho

Usei o Codex como ferramenta de apoio à implementação, à criação e execução de testes e à documentação. Conduzi a definição da referência de interface, persona, escopo e provedores, com atenção ao custo e à simplicidade da solução.

Também orientei os cenários de teste e os resultados esperados, revisei respostas e priorizei correções. Ao identificar propostas complexas para o desafio, direcionei sua simplificação. O trabalho avançou em incrementos, usando consultas, respostas e testes para revisar o resultado de cada etapa.

Exemplos de atendimento e revisão

As cinco conversas abaixo foram executadas em 03/11/2026 com `gemini-3.5-flash-lite`, pela interface via Streamlit AppTest e API real. As falas são reproduzidas das exportações, sem reescrita. Os arquivos vinculados preservam também consultas e fontes.

1. Catálogo e continuidade no PIX

O cliente pede duas opções e depois se refere à primeira. O agente consulta os CSVs e usa o preço calculado em Python.

Cliente

Quero duas opções de violões disponíveis até R$ 1.000. Mostre nome e preço.

Lia

Olá! Temos estas opções de violões disponíveis dentro do seu orçamento:

- Tagima Memphis AC-39 Nylon Natural - R$ 429,90 sem frete [D83].

- Rozini RC-104 Nylon Estudante - R$ 459,90 sem frete [D85].

Cliente

E o primeiro no PIX?

Lia

O violão Tagima Memphis AC-39 Nylon Natural sai por R$ 408,41 sem frete no pagamento via PIX [D83].

Arquivo completo: catálogo e PIX.

2. Promoção e desconto não cumulativo

A resposta combina a consulta do produto com a regra de promoção. Mantém a ressalva de apresentação: o texto não explicita a condição sem frete.

Cliente

Quanto fica o Ohana CK-20 no PIX? Posso somar os 5% à promoção?

Lia

O Ohana CK-20 Concert Natural sai por R$ 439,20 no PIX (preço original de R$ 549,00 com 20% de desconto promocional) [D121].

Não é possível somar o desconto de PIX à promoção, pois as regras da loja determinam que as promoções não são cumulativas e o desconto de PIX não se aplica sobre preços já promocionais [P6.2-p6-1].

Arquivo completo: promoção e PIX.

3. Aplicação da política de parcelamento

O agente recupera a seção específica do manual e verifica a condição de parcela mínima.

Cliente

Uma compra de R$ 480 pode ser dividida em seis vezes sem juros?

Lia

Sim, uma compra de R$ 480,00 pode ser dividida em seis vezes sem juros, pois o valor da parcela (R$ 80,00) atinge o mínimo exigido para essa quantidade de parcelas [P3.1-p3-1].

Arquivo completo: parcelamento.

4. Status e rastreamento de pedido

Consulta feita com **Cliente #2** selecionado. Preserva o total histórico e o rastreamento cadastrado. A expressão inglesa "shipped" é uma ressalva de linguagem.

Cliente

Qual o status, total e rastreamento do meu pedido 8?

Lia

O seu pedido 8 está com o status de enviado (shipped) e o código de rastreamento é BRJL5544332BR [O8]. O valor total histórico é de R$ 349,90 [O8].

Arquivo completo: pedido e rastreamento.

5. Pergunta fora do escopo

A regra de atendimento restringe a loja a instrumentos. Esta conversa não executou nova consulta.

Cliente

Vocês vendem cabos, palhetas ou amplificadores?

Lia

Olá! Na Empório da Música, nós somos especializados em instrumentos musicais, como violões, guitarras, baixos, teclados, baterias e outros instrumentos de cordas, sopro e percussão.

Cabos, palhetas e amplificadores são acessórios e não fazem parte do nosso catálogo de instrumentos.

Posso te ajudar a encontrar algum instrumento específico?

Arquivo completo: fora do escopo.

Critérios de revisão e ajustes

Orientei os testes a partir do comportamento esperado no atendimento: fatos apoiados nas fontes, preço correto, continuidade de contexto, respeito ao escopo e acesso restrito aos pedidos. Também defini expectativas de tom e coleta das informações necessárias antes de orientar devoluções.

A execução foi apoiada por automação e Codex. A revisão das respostas e a priorização das correções fizeram parte da minha condução do projeto. Três casos ilustram esse processo:

Problema observado	Ajuste implementado	Verificação registrada
Pedido sem identificação ou pertencente a outro cliente terminava em erro de referência.	Orientação determinística a partir do resultado da ferramenta, sem revelar o pedido.	C24 e C27 aprovados nos retestes.
Produto descontinuado foi descrito como esgotado, apesar de ter quantidade cadastrada.	Instrução distingue status comercial e quantidade em estoque.	C13 informou descontinuado com 13 unidades, sem oferecer compra.
A resposta acrescentou "sem frete" ao total histórico de um pedido.	Validação conservadora e teste de regressão para a condição não informada.	C25 repetido com total, status e rastreio corretos, sem afirmar composição de frete.

Os retestes demonstram o resultado desses casos. A avaliação ainda registrou ressalvas de linguagem e triagem, e o conjunto completo não foi repetido após o último ajuste.

Melhorias com mais tempo

Começaria pelos controles de resposta e pelo contexto do atendimento. A evolução das consultas acompanharia o crescimento da base, com avaliação de qualidade a cada mudança.

1. **Guardrails e triagem:** validar afirmações de preço, estoque e políticas contra os resultados das ferramentas; estruturar os dados pendentes da triagem e encaminhar dúvidas à equipe. Ampliaria os testes com perguntas novas e tentativas de desviar as regras.
2. **Contexto de atendimentos anteriores:** manter resumos e campos relevantes por cliente identificado, como instrumento de interesse, orçamento e condições já informadas. A recuperação respeitaria autorização e retenção definida; preço, estoque e políticas vigentes seriam consultados novamente nas fontes.
3. **RAG para mais documentação:** avaliar busca híbrida com BM25 e embeddings, seguida de reranking. Refinaria a divisão dos documentos em trechos com contexto, metadados de seção e controle de versão/vigência. Compararia recuperação e fidelidade em um conjunto de perguntas independente.
4. **Consultas para bases maiores:** substituir a leitura dos CSVs por banco de dados ou APIs operacionais, com filtros, índices e paginação. Manteria ferramentas com parâmetros e permissões definidos, preservando os cálculos de preço e as regras de acesso no código.
5. **Fine-tuning de comportamento:** após melhorar dados, prompts e validações, avaliaria um modelo compatível com conversas revisadas para tom, triagem e escolha de ferramentas. Separaria treino e avaliação para medir ganho frente ao modelo base. Preços e disponibilidade continuariam consultados nas fontes.

Autenticação real e integrações de estoque e pedidos seriam necessárias para uso operacional. Essas melhorias são propostas de evolução; a entrega mantém o escopo de protótipo.

Relatórios e exemplos: avaliação com Gemini e índice das cinco conversas. As decisões de implementação estão resumidas no README.